2025 年第九届“数维杯”大学生
数学建模挑战赛论文

题　　目　气象-物候模型下多维度赏花与经济优化策略研究

摘　要

清明节作为兼具自然节气与文化内涵的传统节日，其天气与花期预测对踏青活动规划至关重要。本文基于气象学与物候学原理，结合时间序列分析、有效积温模型、整数规划模型，及经济效益模型，解决了"雨纷纷"天气预测、花期预报及赏花行程优化问题。

针对问题一，本文建立了 **ARIMA 时间序列模型**预测"雨纷纷"现象。首先定义"雨纷纷"为日降雨量在 0.1-9.9mm 内且持续时长≥3 小时，通过 **ADF 检验**确保时间序列平稳性，利用 **LB 检验**排除白噪声，最终构建 ARIMA(p,d,q)模型预测 2026 年七城市降雨量和持续时长，具体结果呈现在正文表 5-1 中。结果显示：**西安、洛阳、吐鲁番、武汉四城将出现"雨纷纷"**，而婺源、杭州、毕节这三座城市不会“雨纷纷”。最后我们对模型的合理性进行了检验，模型均方根误差 RMSE≤0.1979，平均绝对误差 MAE≤0.1466，精度较高，但用模型预测数据与真实值对比绘制的折线图表明模型在前几年的预测效果并不好，于是我们通过**增加训练轮次**并调整训练集和测试集的比例不断修正模型参数。

针对问题二，本文采用**有效积温-多元线性回归混合模型**预测花期。首先以 0℃为阈值温度，计算油菜花、樱花的有效积温，并初步得出始花期预报值。再以降雨量、平均气温、最高气温、最低气温和相对湿度这 5 个气象因子为自变量，以积温模型预报值误差为因变量建立多元线性回归模型修正误差，修正后模型 RMSE 降低至 3.96，精度提升至 95.36%。接着用类似的方法求解落花期，得到最终预测 2026 年婺源油菜花和樱花始花期分别为 3 月 21 日（花期 31 天），4 月 1 日（花期 10 天）；武汉油菜花和樱花始花期分别为 3 月 1 日（花期 26 天），3 月 27 日（花期 11 天）。

针对问题三，本文构建**多约束整数规划模型**规划行程。以景点选择和行程转移 0-1 变量为**决策变量**，以最大化花期和天气的总观赏效用值为**目标函数**，以行程连续性，交通可达性等 7 个因素为**约束条件**。利用 Matlab 编程求解得到最优行程：4 月 4 日去往武汉赏樱花，4 月 5 日去往婺源观赏油菜花，4 月 6 日仍在婺源，赏樱花。

针对问题四，本文首先建立了**经济效益评估模型**，计算出净效益收益与投资回报率。接着分析影响经济效益的影响因素之间的**相关性**，确定对经济效益影响**最大的因素**并通过 Matlab 编程求解，得出 2000 万元投资资金的**效益最大化分配比例**及预期收益（具体结果见正文表 8-3），并提供了相对应的具体措施。最终结果显示把主要投资资金放在能够**提升游客量**和旅游收入的项目上能够实现经济效益最大化。

关键词　ARIMA 模型；有效积温；花期预测；整数规划；经济效益

目　　录

一、问题重述.....1
1.1 问题背景.....1
1.2 问题重述.....1
二、问题分析.....1
2.1 问题 1 的分析.....1
2.2 问题 2 的分析.....2
2.3 问题 3 的分析.....2
2.4 问题 4 的分析.....2
三、模型假设.....3
四、定义与符号说明.....3
五、问题一模型的建立与求解.....3
5.1“雨纷纷”降雨量及降雨持续时间的标准.....3
5.2 预测模型的建立.....4
5.2.1 数据的提取和预处理.....4
5.2.2 时间序列分析模型的建立.....4
5.2.3 ARIMA 模型的建立.....5
5.3 ARIMA 模型的求解.....7
5.4 问题一预测模型的合理性检验及修正.....8
5.4.1 预测模型的合理性检验.....9
5.4.2 模型的修正.....9
六、问题二模型的建立与求解.....10
6.1 基于有效积温法的始花期预报模型的建立.....10
6.2 多元线性回归模型修正积温预报模型.....11
6.2.1 确定自变量和因变量.....11
6.2.2 多元线性回归模型的建立与求解.....12
6.3 多元线性回归模型求解落花期.....13
七、问题三模型的建立与求解.....15
7.1 问题三符号说明.....15
7.2 整数规划模型的建立.....16
7.2.1 引入决策变量.....16
7.2.2 写出目标函数.....16
7.2.3 明确约束条件.....17
7.3 多约束整数规划模型的求解.....18
八、问题四模型的建立与求解.....20
8.1 经济效益评估模型的建立.....20
8.2 影响经济效益因素的相关性分析.....22
8.3 经济效益评估模型的求解.....24
九、模型的评价及优化.....26
9.1 模型的优点（建模方法创新、求解特色等）.....26
9.2 模型的缺点.....26
9.3 模型的推广.....27
9.4 模型的改进.....27
参考文献.....28

一、问题重述

1.1 问题背景

清明节作为中国重要的传统节日和自然节气，承载着深厚的文化内涵与自然意义。此时正值春意盎然之际，南方气清景明，北方冰雪消融，人们通过踏青、扫墓等活动与自然互动。然而，清明时节的天气变化复杂，尤其是“清明时节雨纷纷”的现象，以及杏花、油菜花、杜鹃花、樱花、牡丹等花卉的花期不确定性，给人们的出行和赏花活动带来了诸多不便。同时，随着文旅产业的快速发展，如何精准预测天气和花期，优化旅游体验，延长“赏花经济”产业链，已成为地方政府和文旅行业亟待解决的关键问题。

1.2 问题重述

1.问题一：根据气象局给出的标准，明确“雨纷纷”现象对应的降雨量区间及降雨持续时间；建立数学模型预测 2026 年西安、吐鲁番、婺源、杭州、毕节、武汉、洛阳会不会发生“雨纷纷”现象；利用 2006-2025 这近 20 年的数据验证所建模型的合理性并给出修正方法。

2.问题二：根据物候学知识，从春季开花类植物：杏花、油菜花、杜鹃花、樱花、牡丹中选择 2-3 中花卉，预测它们在 2026 年的始花期和开花天数。

3.问题三：根据问题 2 的花期预报模型，综合考虑天气因素等其他出游因素，制作一份清明赏花自由行攻略。

4.问题四：为延长地区“赏花经济”产业链，给当地政府提供一些具体措施，并用数学模型说明采取这些措施会带来的经济效益。

二、问题分析

2.1 问题 1 的分析

首先需要查阅相关资料，给“雨纷纷”现象下一个明确的定义，包括明确的降雨量及降雨持续时间。接着发现年份分别和降雨量、降雨持续时间形成了两个时间序列，从而确定建立时间序列分析模型，对两个时间序列依次进行平稳性检验、白噪声检验，接着就能识别出建立时间序列分析模型中的哪一个模型，再用具体公式进行参数估计，通过 Matlab 编程即可求解。最后将所用 2006-2025 的数据按照 7:3 的比例划分，用前一份

的数据训练出后一份的数据并与真实数据比较，绘制折线图对比，即可对模型的合理性进行评估，对参数值修正。

2.2 问题 2 的分析

问题二要求我们预测几种花的花期，基于物候学原理可以首先构建出有效积温模型，在选取了合适的阈值温度后，分别计算婺源和武汉油菜花和樱花开花所需的有效积温天数，初步预测 2026 年始花期。但是误差可能较大，主要是因为没有考虑气象因素对始花期的影响。因此需要引入降雨量、气温、湿度等气象因子，建立多元线性回归修正模型，显著降低预测误差。落花期预测则直接关联气象因子与历史数据，最终输出 2026 年花期完整结果。

2.3 问题 3 的分析

问题三在问题二确定的始花期和开花时长的基础上，要求我们制定清明出行赏花攻略。主要考虑降雨天气、花朵观赏效用值，游客密度和交通成本这四个因素，可以建立多约束整数规划模型。以景点选择和行程转移 0-1 变量为决策变量，以最大化花朵和天气的总观赏效用值为目标函数，以行程连续性，交通可达性，预算控制，景点开放时间，游览时长下限，每日时间窗，疲劳度限制为约束条件，建立多约束整数规划模型。利用 Matlab 编程求解最优行程。

2.4 问题 4 的分析

问题四要求为延长地区“赏花经济”产业链提供具体措施，并用数学模型说明其经济效益。首先，通过动态游客需求函数分析花期延长、宣传投入等因素对游客量的影响；其次，建立人均消费模型，计算门票、交通、食宿及购物等收入；最后，结合投资成本函数和产业链乘数效应，评估净收益与投资回报率（ROI）。至此，经济效益评估模型建立完毕，接下来分析影响经济效益的因素之间的相关性，确定对经济效益影响最大的因素并通过 Matlab 编程求解，科学分配投资资金至承载力提升、花卉项目开发等领域，最大化经济效益。

三、模型假设

1. 假设所使用的气象数据（包括降水量、温度、湿度等）是准确且代表性的，且历史气象数据能够有效反映未来天气变化的趋势，用于模型的训练和验证。

2. 假设春季开花类作物从萌动到始花的生理进程主要由温度积累驱动。

3. 假设游客的出行行为与花期和天气状况高度相关，游客在不同时间段的选择偏好可以通过花卉的观赏价值和天气影响的综合效用来量化。

4. 假设景点之间的交通时效和可达性是固定的，且游客在规划行程时能够遵循最优路径并遵守景点的开放时间和路线约束。

5. 假设游客需求与花期长度、宣传投入呈指数关系，短期内无饱和效应。

四、定义与符号说明

符号定义	符号说明
n	样本量
$\hat{p}_k$	滞后 k 阶的样本自相关系数
h	滞后阶数
d	差分阶数
ε_t	白噪声误差项
Φ_i	自回归系数
ϵ_t	预测误差项
GDD	有效积温
T_i	第i日的平均气温
G^*	多年平均有效积温值
y_E	误差项
Y_L	落花期日序数

五、问题一模型的建立与求解

5.1“雨纷纷”降雨量及降雨持续时间的标准

根据气象行业国家标准 GB/T28592—2012，降雨量在 0.1—9.9 毫米/天时，我们称其为小雨或者细雨；一般情况下，降雨持续时间大于等于 3 小时时，可以定义为题目中

所说的“雨纷纷”。综上，本文规定降雨量在 0.1—9.9 毫米/天，并且降雨持续时间大于等于 3 小时时，为“雨纷纷”现象。

5.2 预测模型的建立

5.2.1 数据的提取和预处理

首先，我们根据 NOAA 下设的国家环境信息中心发布的 1929 至今的全球站点逐日气象数据集，提取出 2006—2025 这近 20 年每年 4 月 4 日到 4 月 6 日的降水量。发现它们形成了一个时间序列，接下来我们对这些时间序列进行分析，在对模型进行参数估计与检验后对未来 7 个城市 2026 年的降水量序列值进行预测并对预测结果进行评价，以此来验证模型的合理性。

提取出数据后，我们发现部分项目存在缺失值，我们对缺失值的处理方法是用历年同期非缺测数据的平均值代替。

5.2.2 时间序列分析模型的建立

时间序列分析的一般流程如下：

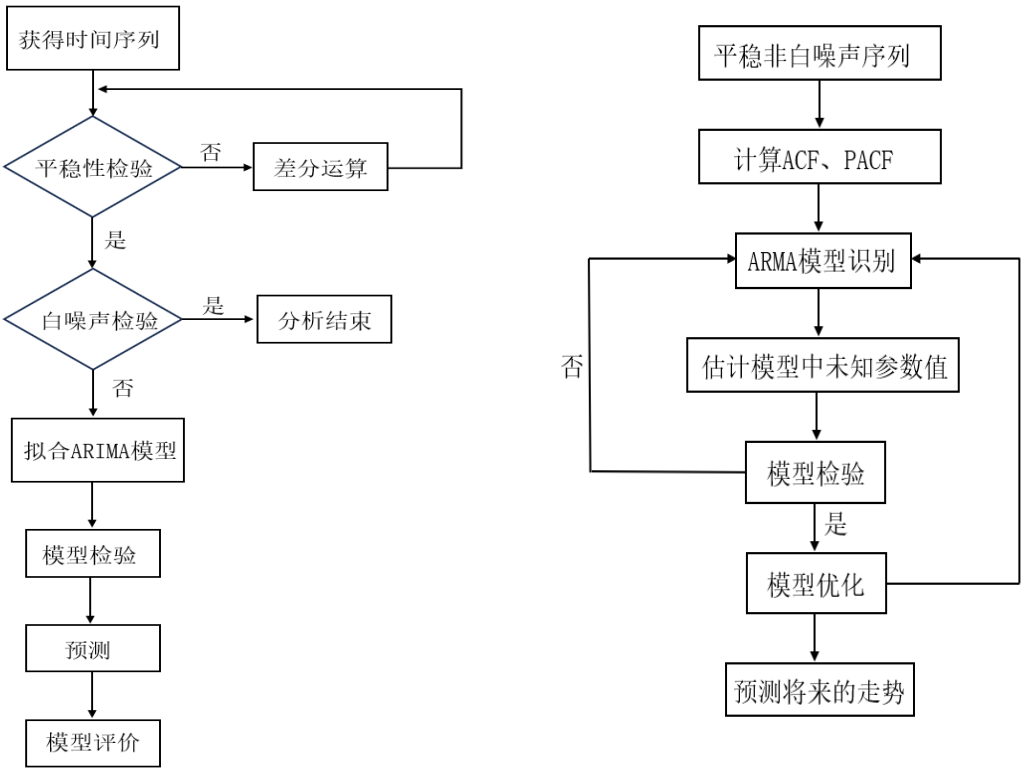


图 5-1 时间序列分析的一般流程图

在获取了 7 个城市 2006-2025 这 20 年每年 4 月 4 日到 4 月 6 日的降雨量数据后，我们对这些时间序列按照如上图 5-1 所示的流程进行分析，由于数据过于庞大，在正文中，我们仅以西安这个城市为例具体展示它的降雨量和降雨持续时间的时间序列分析过程和结果，其余 6 个城市的分析过程类似，具体结果见支撑材料。

5.2.3 ARIMA 模型的建立

■平稳性检验

在获取西安 2006-2025 这 20 年每年 4 月 4 日到 4 月 6 日的降雨量和降雨持续时间共 2 个时间序列后，首先分别对它们进行平稳性检验，这里主要采用增广迪基 - 富勒检验（Augmented Dickey - Fuller Test，ADF 检验）方法来进行单位根检验，并利用 Matlab 编程实现。具体步骤如下：

Step1：首先，设定原假设和备择假设：

原假设（H_0）：时间序列是非平稳的，即存在单位根。

备择假设（H_1）：时间序列是平稳的，即不存在单位根。

Step2：其次，对时间序列进行去除趋势项处理和季节性调整，以确保时间序列的平稳性。因为本题所给数据不存在明显的趋势和季节性波动，所以不做上述处理。

Step3：然后，构建 ADF 检验模型：

已知 ADF 检验是通过回归模型来检验时间序列的平稳性。对于时间序列$\{y_t\}$，ADF 检验的基本模型如下：

$$y_t = \alpha + \beta t + \gamma y_{t-1} + \delta_1 y_{t-2} + \cdots + \delta_k y_{t-k} + \varepsilon_t \tag{1}$$

其中y_t是时间序列在时刻t的观测值，α是截距项，β_t是时间趋势项，γ是滞后一期的系数，δ_i是滞后i期的系数，k是滞后阶数，ε_t是误差项。

对于滞后阶数k的选取原则是：根据时间序列的长度确定一个最大滞后阶数，基于信息准则（AIC）最小值的滞后阶数来作为最优的滞后阶数，然后将其代入公式（1）。

Step4：接下来，计算 ADF 统计量：

根据 ADF 检验模型，我们可以通过编程软件 Matlab 计算 ADF 统计量。ADF 统计量是一个 t 统计量，用于检验γ 是否等于 0。计算公式如下：

$$ADF = \frac{\gamma - 0}{\sigma(\gamma)} \tag{2}$$

其中$\sigma(\gamma)$是γ的标准误差。

利用 Matlab 编程求解出的西安城市的 ADF 统计量为-4.5320。

Step5：最后，选择 5%的显著性水平作为判断依据并结合样本量（本文为总体），通过查找相应的临界值表（本文查取的是 MacKinnon 临界值表）确定对应的 ADF 临界值。比较 ADF 临界值与计算得到的 ADF 统计量，以确定是否拒绝原假设。如果 ADF 统计量小于临界值，则拒绝原假设，认为时间序列是平稳的；否则，接受原假设，认为时间序列是非平稳的，需要进行**差分处理**以获得平稳时间序列。

■ 白噪声检验及 ACF 和 PACF 图的绘制

通过对非平稳序列的差分化处理使其平稳化，我们得到了 2 个新的时间序列，接下来进行检验。

Step1：建立原假设和备择假设：

原假设（H_0）：时间序列是白噪声，即序列中的观测值独立，且具有恒定的方差。

备择假设（H_1）：时间序列不是白噪声，即序列中的观测值存在相关性或方差不恒定。

Step2：选择检验统计量：

对于白噪声检验，我们选择 Ljung - Box （LB）检验法，LB 检验基于一系列滞后系数，通过计算待验时间序列的自相关系数和偏自相关系数建立模型，并检验模型的残差序列。

Step3：计算检验的统计量值与 p 值：

使用编程软件 Matlab 计算 LB 检验的 Q 统计量并据此计算 p 值，选用时间序列的长度作为滞后阶数。Q 统计量的计算公式如下：

$$Q = n(n+2)\sum_{k=1}^{h}\frac{\hat{p}_k^2}{n-k} \tag{3}$$

其中 n 是样本量，$\hat{p}_k$ 是滞后 k 阶的样本自相关系数，h 是指定的滞后阶数。

通过 Matlab 编程计算出的西安城市的滞后阶数 h=7，Q 统计量=15.1650。

Step4：比较 p 值和设定的显著性水平：

选择 5%的显著性水平作为判断依据，通过 Matlab 编程计算出的西安城市的 p 值为 0.0041，小于 0.05，因此拒绝原假设，认为数据序列不是白噪声，即存在自相关性。

至此，我们得到了平稳的非白噪声序列，接下来绘制它们的自相关系数 ACF 和偏自相关系数 PACF 图。结果如下图 5-2 所示。通过观察可以发现，西安城市降雨量时间

序列的 ACF 和 PACF 图均呈现出**拖尾**形状，类似的，降雨持续时间的序列的也呈现出拖尾形状，结合上文对非平稳序列进行的差分化处理，我们综合建立 ARIMA 模型。

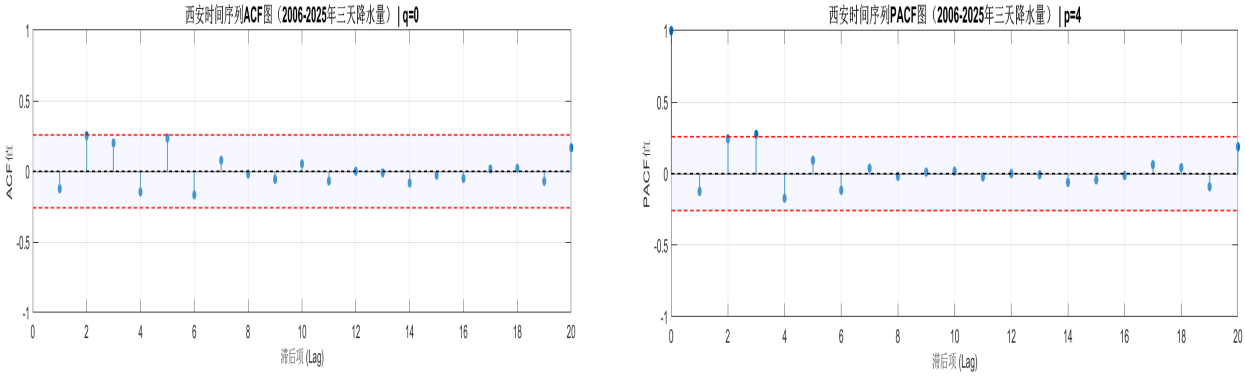


图 5-2 西安城市降雨量时间序列的 ACF 和 PACF 图

■ ARIMA 模型的识别

ARIMA 模型的公式如下：

$$\Phi_p(B)(1-B)^d y_t = \theta_q(B)\varepsilon_t \tag{4}$$

其中，$\Phi_p(B)$是自回归多项式，$\theta_q(B)$ 是移动平均多项式，B 是后移算子，d 是差分阶数，y_t是移动平均多项式，ε_t是白噪声误差项。

利用 Matlab 编程就可以得到参数的估计值，进而可以用 ARIMA 模型进行 2026 年数据的预测。预测公式如下：

$$\hat{y}_{t+h} = \mu + \Phi_i \hat{y}_{t+h-1} + \ldots + \Phi_p \hat{y}_{t+h-p} + \theta_1 \epsilon_{t+h-1} + \ldots + \theta_q \epsilon_{t+h-q} \tag{5}$$

其中，$\hat{y}_{t+h}$是未来第 h 步的预测值，μ是常数项，Φ_i是自回归系数，θ_j是移动平均系数，ϵ_t是误差项。

5.3 ARIMA 模型的求解

通过 Matlab 编程我们得到了参数的估计值并根据公式（5）以及西安、吐鲁番、婺源、杭州、毕节、武汉、洛阳这 7 座城市 2006—2025 共 20 年间 4 月 4 日—4 月 6 日降雨量及降雨持续时间的数据，预测计算出了它们 2026 年 4 月 4 日—4 月 6 日降雨量及降雨持续时间的数据，具体结果如下表 5-1：

表 5-1 2026 年 4 月 4 日—4 月 6 日降雨量及降雨持续时间

城市	日期	预测降雨量	预测降雨时长
Bijie	2026-04-04	10.05	5.43
Bijie	2026-04-05	10.24	8.31
Bijie	2026-04-06	15.8	4.67
Hangzhou	2026-04-04	10.78	1.24
Hangzhou	2026-04-05	12.1	1.80

Hangzhou	2026-04-06	12.12	6.4
Luoyang	2026-04-04	14.23	5.48
Luoyang	2026-04-05	8.89	6.41
Luoyang	2026-04-06	5.73	9.26
Turpan	2026-04-04	9.36	8.72
Turpan	2026-04-05	8.34	5.46
Turpan	2026-04-06	15.35	6.92
Wuhan	2026-04-04	12.25	8.57
Wuhan	2026-04-05	10.65	4.47
Wuhan	2026-04-06	11.22	7.47
Wuyuan	2026-04-04	8.1	6.72
Wuyuan	2026-04-05	8.92	5.99
Wuyuan	2026-04-06	13.73	1.83
Xi'an	2026-04-04	15.03	3.01
Xi'an	2026-04-05	9.85	3.97
Xi'an	2026-04-06	12.11	4.05

为了更直观的判断出这些城市在 2026 年 4 月 4 日—4 月 6 日之间会不会产生“雨纷纷”现象，我们将上表 5-1 的数据进行可视化。具体结果如下图 5-3。

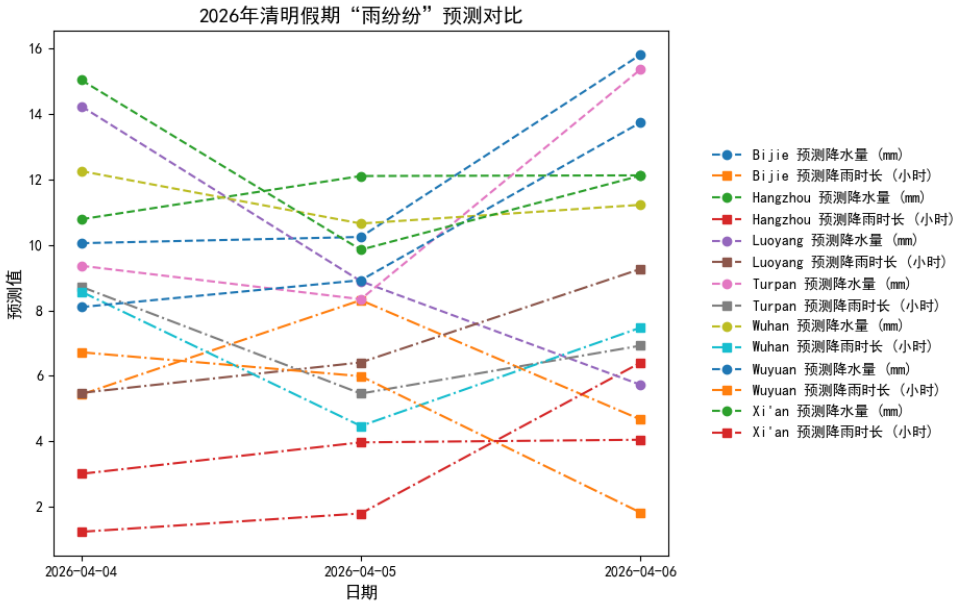


图 5-3 预测模型的结果图

分析上表 5-1 的数据并且观察上图 5-3 可以发现，表 5-1 中标红的数据都满足降雨量在 0.1-9.9 毫米/天并且降雨持续时长均在 3 小时/天以上，符合本文 5.1 节定义的“雨纷纷”的概念，因此可以认为西安、洛阳、吐鲁番、武汉这四座城市会发生“雨纷纷”现象；而婺源、杭州、毕节这三座城市不会发生“雨纷纷”现象。

5.4 问题一预测模型的合理性检验及修正

5.4.1 预测模型的合理性检验

为了验证上文所建 ARIMA 预测模型的合理性，我们将西安、吐鲁番、婺源、杭州、毕节、武汉、洛阳这 7 座城市 2006—2025 共 20 年间 4 月 4 日—4 月 6 日降雨量及降雨持续时间的数据按照 7:3 的比例划分，前 7/10 的部分作为训练集，用于测试后 3/10 部分的数据，并和后 3/10 部分的实际数据进行比对，绘制出两个折线图。下图 5-4 是得到的结果图。

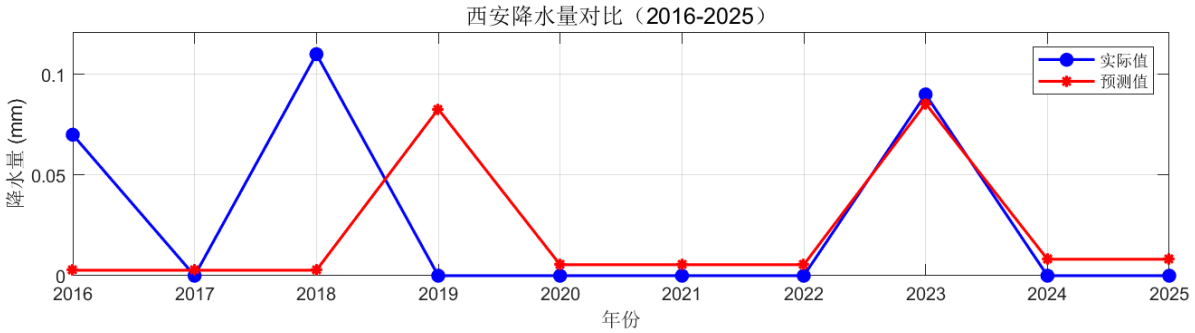


图 5-4 模型预测值和实际值的对比折线图

并且，通过回归分析，我们还得到了均方根误差即 RMSE 和平均绝对误差即 MAE，它们的值越小，即可说明模型越精确。具体结果见下表 5-2。

表 5-2 回归分析的 RMSE 和 MAE（单位：mm）

日期	RMSE	MAE
4 月 4 日	0.1979	0.1466
4 月 5 日	0.0710	0.0495
4 月 6 日	0.0522	0.0414

观察发现，均方根误差和平均绝对误差都非常小，因此可以认为所建预测模型基本合理。

5.4.2 模型的修正

由于时序数据有一个核心的矛盾—时间依赖性，因此模型需基于“历史数据”预测“未来数据”。若采用传统随机分割（训练集和测试集时间混杂），会导致模型 “偷看” 未来数据（数据泄露），评估结果无法真实反映模型对未来的预测能力。因此，训练 - 测试分割需平衡模型训练充分性和测试集代表性。原方案（14 年训练 + 6 年测试）属于常规 70%-30% 分割，但实际拟合效果仍有待提升，这是因为测试集过小（仅 6 年），无法充分暴露模型在长期数据上的泛化问题。并且训练集冗余（14 年数据）：若时间序列的 “有效模式” 集中在近期（如近 10 年），早期数据（如 2006-2010

年）可能包含过时信息，反而干扰模型学习。

综上所述，我们可以通过增加训练轮次的同时，调整训练—测试集分割比例，以此来对模型进行不断修正。下表 5-3 就展示了以 1:1 的比例划分时间序列后得到的 RMSE 和 MAE 值。可以明显发现 RMSE 和 MAE 的值减小，说明模型的精度变高。

表 5-4 以 1:1 比例划分后得到预测模型的 RMSE 和 MAE 值

日期	RMSE	MAE
4 月 4 日	0.0911	0.0866
4 月 5 日	0.0481	0.0297
4 月 6 日	0.0221	0.0170

六、问题二模型的建立与求解

6.1 基于有效积温法的始花期预报模型的建立

根据物候学知识，我们可以建立**有效积温模型**，计算达到婺源和武汉的油菜花和樱花开花所需积温的天数来预测油菜花和樱花在 2026 的始花期（开始开花的那一天）。[1] 具体原理为：每种作物都有其生长发育的下限温度（生物学零度），只有当环境温度高于这个下限温度时，作物才开始生长发育。作物完成某一发育阶段所需的总热量是一个常数，这个常数就是有效积温，我们通过计算达到有效积温所需要的天数，即可确定花期。有效积温（GDD）的计算公式如下：

$$GDD = \sum_{i=1}^{n} (T_i - T_0) \quad (T_i > T_0) \tag{6}$$

其中，n 为发育期历经的天数，T_i 为第 i 日平均气温（℃），T_0 为阈值温度（℃）。利用日平均气温分别计算油菜花和樱花的逐年有效积温，再以多年平均有效积温值 G^* 为有效积温指标，令 $GDD \geq G^*$，反解出 n 的最小值，即可得到预报始花期。

通过查阅文献，我们认为采用 0℃作为婺源和武汉的油菜花和樱花积温阈值温度，通过计算 2016-2025 年的平均有效积温值，得到分别以 280℃、590℃作为有效积温指标较为合理。

下表 6-1、6-2 分别展示了利用有效积温法预测出的 2016-2025 年间婺源和武汉的油菜花和樱花的始花期和实际日期的数据以及误差。

表 6-1 婺源油菜花和樱花 2016-2025 年间预报始花期和实际日期

	年份	实际日期	预报日期	误差		年份	实际日期	预报日期	误差
油菜花	2016	03-04	03-06	-2	樱花	2016	03-12	03-15	-3
	2017	02-26	02-26	0		2017	03-18	03-27	-9
	2018	03-08	03-10	-2		2018	03-20	03-28	-8
	2019	02-20	03-05	-13		2019	03-19	03-19	0
	2020	03-02	03-06	-4		2020	03-15	03-24	-9
	2021	03-02	03-03	-1		2021	03-08	03-19	-11
	2022	02-28	03-09	-9		2022	03-18	03-26	-8
	2023	02-22	03-05	-11		2023	03-22	04-03	-12
	2024	02-20	02-25	-5		2024	03-16	03-20	-4
	2025	02-27	03-02	-3		2025	03-14	03-16	-2

表 6-2 武汉油菜花和樱花 2016-2025 年间预报始花期和实际日期

	年份	实际日期	预报日期	误差		年份	实际日期	预报日期	误差
油菜花	2016	03-05	03-13	-7	樱花	2016	03-10	03-15	-5
	2017	03-10	03-12	-2		2017	03-05	03-08	-3
	2018	03-08	03-13	-5		2018	03-10	03-10	0
	2019	03-12	03-22	-10		2019	03-12	03-14	-2
	2020	03-03	03-22	-9		2020	03-15	03-21	-6
	2021	03-07	03-10	-3		2021	03-10	03-17	-7
	2022	03-09	03-15	-4		2022	03-12	03-12	0
	2023	03-15	03-28	-13		2023	03-13	03-25	-12
	2024	03-06	03-15	-9		2024	03-11	03-15	-4
	2025	03-08	03-14	-6		2025	03-13	03-21	-8

注：上述两表中的误差均指基于有效积温法模拟预报的始花期与实际日期相差的天数，正值表示实际值晚于预报值，负值表示实际值早于预报值，零表示二者完全吻合。

6.2 多元线性回归模型修正积温预报模型

6.2.1 确定自变量和因变量

首先，我们采用 Julian 日换算方法，[2]将始花期转化为距 1 月 1 日的实际天数，得到婺源和武汉的油菜花和樱花各生育期的日序数，例如，日序数 60 即表示始花期为 3 月 1 日。通过观察上述表 6-1、6-2 的误差项发现，仅用积温模型预测出的始花期与实际值之间存在较大误差，主要原因在于始花期还会受到降雨量、平均气温、最高气温、最低气温和相对湿度等环境因素的影响，因此我们接下来在考虑这 5 个主要影响因素的前提下，以**积温模型得到的误差值为因变量**、以降雨量、平均气温、最高气温、最低气温和相对湿度为自变量，建立多元线性回归模型，来修正积温预报模型。

我们利用 2016-2022 年的数据建模，2023-2025 年数据用于模型检验。首先，我们根据上表 6-1、表 6-2 中的始花期转换为日序数值，并分别计算婺源油菜花、婺源樱花、

武汉油菜花、武汉樱花在 2016-2025 年间的始花期平均日序数值，得到婺源油菜花、婺源樱花、武汉油菜花、武汉樱花始花期出现的平均出现日期分别为 2 月 16 日、3 月 17 日、3 月 8 日、3 月 11 日。我们将此作为 2026 年婺源和武汉的油菜花和樱花的预测值。并且考虑到模型的精度，选用 2 月中旬到 3 月下旬的降雨量、平均气温、最高气温、最低气温和相对湿度数据为自变量，以积温模型得到的误差值为因变量，建立多元线性回归模型，用来求出 2026 年的误差项。最后用 2026 年婺源和武汉的油菜花和樱花的预测值减去用多元线性回归模型求出的误差项，就是最终预测的 2026 年始花期值。

6.2.2 多元线性回归模型的建立与求解

多元线性回归方程如下：

$$y_E = \alpha_0 + \beta_1 T_{avg} + \beta_2 T_{\max} + \beta_3 T_{\min} + \beta_4 RH + \beta_5 PRCP + \epsilon \tag{7}$$

其中，y_E 为误差项，α_0 为截距项，β_i $(i = 1, 2, 3, 4, 5)$ 分别为平均温度、最高气温、最低气温、相对湿度、降雨量对开花日期的敏感系数（天/℃），ϵ 为随机误差项，服从正态分布。

代入 2016-2025 年间的始花期与预报值之间的误差项数据以及 2 月中旬到 3 月下旬的降雨量、平均气温、最高气温、最低气温和相对湿度数据，利用 Matlab 编程计算，得到方程的复相关系数 R=0.655，P<0.05，因此，该回归模型成立。

以婺源油菜花为例，最终计算结果如下：

表 6-3 积温模型和气象因子修正模型精度比较

模型名称	RMSE 值	RE 值	模拟精度
积温模型	5.09	7.62%	94.12%
气象因子修正模型	3.96	5.67%	95.36%

上表 6-3 表明，用气象因子改进之后的模型的预测效果比有效积温法好。

用气象因子模型得到的预测值与实际值之间的对比折线图如下图 6-1 所示。通过观察折线图的吻合情况也可发现修正后的结合气象因子的预测模型拟合效果良好。

综上所述，我们将积温模型得到的 2026 年始花期预测值减去考虑气象因子的多元线性回归模型得到的误差值即可得到最终的 2026 年婺源油菜花、婺源樱花、武汉油菜花、武汉樱花始花期具体数值，结果如下表 6-4 所示。

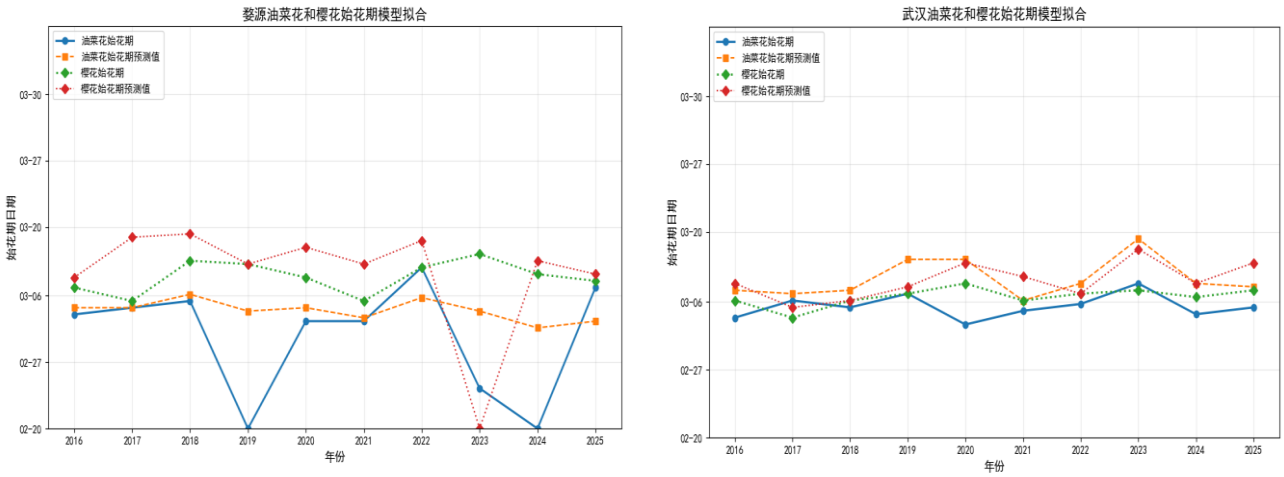


图 6-1 气象因子模型得到的预测值与实际值之间的对比折线图

表 6-4 2026 年婺源和武汉的油菜花和樱花始花期预测值

地区 \ 品种	油菜花始花期	樱花始花期
婺源	3 月 21 日	4 月 1 日
武汉	3 月 10 日	3 月 27 日

6.3 多元线性回归模型求解落花期

通过查阅资料，我们可以得到武汉和婺源的油菜花和樱花 2016-2025 年间的落花期，具体数据见下表 6-5、表 6-6。

表 6-5 武汉油菜花和樱花 2016-2025 年间的落花期

	年份	实际日期		年份	实际日期
	2016	4 月 6 日		2016	3 月 26 日
	2017	4 月 10 日		2017	3 月 21 日
武	2018	4 月 11 日	武	2018	3 月 26 日
汉	2019	4 月 12 日	汉	2019	3 月 29 日
油	2020	4 月 9 日	樱	2020	4 月 1 日
菜	2021	4 月 13 日	花	2021	3 月 26 日
花	2022	4 月 16 日		2022	3 月 28 日
	2023	4 月 15 日		2023	3 月 31 日
	2024	4 月 11 日		2024	3 月 29 日
	2025	4 月 17 日		2025	3 月 30 日

表 6-6 婺源油菜花和樱花 2016-2025 年间的落花期

	年份	实际日期		年份	实际日期
婺源油菜花	2016	4 月 13 日	婺源樱花	2016	3 月 29 日
	2017	4 月 5 日		2017	4 月 4 日
	2018	4 月 10 日		2018	4 月 5 日
	2019	3 月 24 日		2019	4 月 6 日
	2020	4 月 2 日		2020	4 月 2 日
	2021	4 月 4 日		2021	3 月 27 日
	2022	4 月 5 日		2022	4 月 5 日
	2023	4 月 8 日		2023	4 月 11 日
	2024	4 月 10 日		2024	4 月 4 日
	2025	4 月 22 日		2025	4 月 3 日

与预测始花期不同的是，在预测落花期时，不需要用到积温模型，直接考虑 5 种主要气象因子：降雨量、平均气温、最高气温、最低气温和相对湿度对植物开花时长的影响，建立多元线性回归模型。在计算均方根误差 RMSE 值和相对误差 RE 值之后对模型进行评价，误差越小，模型精度越高，表明可以用于预测 2026 年的落花期。

多元线性回归方程如下：

$$Y_L = \varphi_0 + \gamma_1 T_{avg} + \gamma_2 T_{\max} + \gamma_3 T_{\min} + \gamma_4 RH + \gamma_5 PRCP + \delta \tag{8}$$

其中， Y_L 为落花期日序数， φ_0 为截距项， $\gamma_i (i = 1, 2, 3, 4, 5)$ 分别为平均温度、最高气温、最低气温、相对湿度、降雨量对开花日期的敏感系数（天/℃）， δ 为随机误差项，服从正态分布。

代入 2016-2025 年间的落花期数据以及 3 月下旬到 4 月下旬的降雨量、平均气温、最高气温、最低气温和相对湿度数据，利用 Matlab 编程计算，得到方程的复相关系数 R =0.535，P<0.05，因此，该回归模型成立。以婺源油菜花为例，最终计算结果为：RMSE 值=4.08，RE 值=6.56，模型精度为 92.44%，我们认为模型拟合效果较好，可以用于与预测 2026 年的落花期数据。用多元线性回归模型得到的落花期预测值与实际值之间的对比折线图如下图 6-1 所示。通过观察折线图的吻合情况可发现该预测模型拟合效果良好。

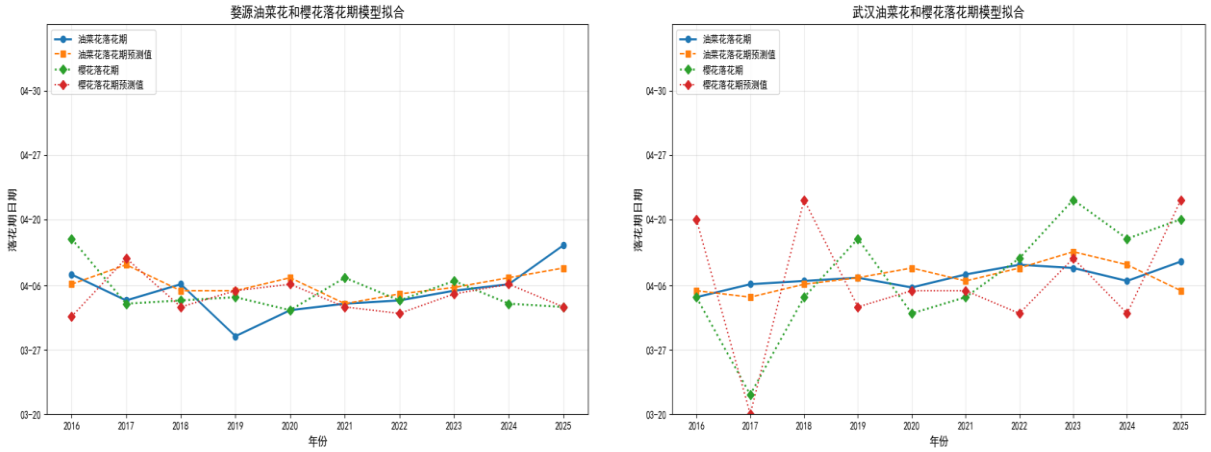


图 6-1 多元线性回归模型得到的落花期预测值与实际值之间的对比折线图

在确定可使用该模型进行预测后的具体操作方式为，以 2006-2025 年降雨量、平均气温、最高气温、最低气温和相对湿度的数据为基准，结合第一问建立的 ARIMA 模型预测出 2026 年降雨量、平均气温、最高气温、最低气温和相对湿度的数据，代入方程（8），即可求出预测的 2026 年婺源油菜花、婺源樱花、武汉油菜花、武汉樱花的落花期，用它减去 6.22 节求出的始花期，就是最终的开花持续时间（花期）。利用 Matlab 编程求解，最终得到的结果如下表 6-7。

表 6-7 2026 年婺源和武汉的油菜花和樱花落花期预测值

地区 \ 品种	油菜花落花期	樱花落花期
婺源	4 月 22 日	4 月 11 日
武汉	4 月 6 日	4 月 6 日

综合 6.2 节对始花期的预测和 6.3 节对落花期的预测，我们得出最终的始花期和开花持续时间（花期）。结果如下表 6-8 所示。

表 6-8 问题二 2026 年开花情况预测结果

地区 \ 品种	油菜花始花期	开花持续时间	樱花始花期	开花持续时间
婺源	3 月 21 日	31 天	4 月 1 日	10 天
武汉	3 月 10 日	26 天	3 月 27 日	11 天

结合植物学常识知识我们认为上述结果基本合理。

七、问题三模型的建立与求解

7.1 问题三符号说明

结合问题二中我们给出的婺源和武汉的油菜花和樱花始花期和开花天数，建立多约

束条件下的最大化总观赏效用整数规划模型，通过比较最大化总观赏效用值，综合考虑游客密度和交通成本这两个因素，从而确定出清明节期间的出行攻略。模型建立的核心是从多个备选景点中，筛选出花况最佳、天气最宜、交通便捷且成本经济的景点，并且还要合理规划游览路线和时间安排，以最大化游客的踏青赏花体验。

由于问题三涉及的符号较多，我们先在此进行符号说明。见下表 7-1。

表 7-1 问题三符号说明

符号	说明	符号	说明
H_i^{open}	景点i当日可入园的时间槽集合	w_i	景点i的静态吸引权重
m_i	景点i最短浏览时长	$F_i(t)$	景点i在时间t的花开观赏指数
h_{start}	每日最早出发时间槽	$R_i(t)$	景点i在时间t的降雨惩罚函数
h_{end}	每日最晚返程时间槽	$P_i^{rain}(t)$	景点i在时间t的”雨纷纷”概率
$T_{\max}$	每日总步行/车程时长上限	$Y_{bloom,i}$	景点i的始花日
τ_{ij}	景点i到景点j的交通耗时	Y_{peak}	景点i的盛花日
C_i	景点i的花费	$Y_{duration}$	景点i的花期结束日
$C_{\max}$	游客预算	L_i	景点i的花期长度
$P_{i,t}$	景点i在时间t的观赏效用	η	降雨惩罚函数的灵敏度系数

7.2 整数规划模型的建立

7.2.1 引入决策变量

引入 0-1 决策变量$w_{i,d,h}$表示游客在清明假期第d天的第h个时间槽是否选择浏览景点i，$y_{i,j,d,h}$表示在(d,h)时段后由i移动至j，这里我们假设 4 个小时为一个时间槽：

$$w_{i,d,h}=\begin{cases}1,\text{游客在时间槽}(d,h)\text{选择景点}i\\0,\text{否则不选择景点}i\end{cases} \tag{9}$$

$$y_{i,j,d,h}=\begin{cases}1,\text{游客在时间槽}(d,h)\text{选择由}i\text{至}j\\0,\text{否则不前往景点}j\end{cases} \tag{10}$$

7.2.2 写出目标函数

记花开观赏指数为$F_i(t)$，一般地，赏花价值与花卉盛放程度正相关。利用问题 2 的花期预测结果，将始花至盛花区间的花况映射为[0,1]区间指数。$F_i(t)$的表达式具体如下：

$$F_i(t)\begin{cases}0, & t<Y_{bloom,i}\\ \dfrac{t-Y_{bloom,i}}{Y_{peak,i}-Y_{bloom,i}}, & Y_{bloom,i}\leqslant t\leqslant Y_{peak,i}\\ 1, & Y_{peak,i}<t<Y_{duration,i}\\ \dfrac{Y_{duration,i}-t}{Y_{duration,i}-Y_{peak,i}}, & Y_{duration,i}\leqslant t\leqslant Y_{duration,i}+L_i\\ 0, & t>Y_{duration,i}+L_i\end{cases} \tag{11}$$

便于求解目标函数的表达式，我们先定义如几个概念：

◆ 降雨惩罚函数

考虑到细雨会影响观光体验，在这里引入惩罚函数的概念。将问题 1 的“雨纷纷”概率$P_i^{rain}(t)$转化为效用惩罚，设置灵敏度系数η，则降雨惩罚函数$R_i(t)$的计算公式为：

$$R_i(t)=\exp(-\eta P_i^{rain}(t))\in(0,1] \tag{12}$$

◆综合观赏效用

花况与天气共同决定即时观赏价值。再乘以景点静态吸引权重w_i（历史口碑、人流承载、门票性价比等），即可得到单位时间效用$P_{i,t}$。

$$P_{i,t}=w_iF_i(t)R_i(t) \tag{13}$$

◆最大化总观赏效用

在给定假期D天、每日H个时间槽下，选择景点-时间组合以最大化观赏效用总和。表达式如下公式（14）所示。

$$\max\sum_{d=1}^{D}\sum_{h=1}^{H}\sum_{i=1}^{I}P_{i,t_{d,h}}\cdot w_{i,d,h} \tag{14}$$

综上所述，公式（14）即为该规划模型中的目标函数。

7.2.3 明确约束条件

■ **行程连续性约束**:

每个时间槽只能待在一个地方；同一时间不可分身，因此有表达式：

$$\sum_i w_{i,d,h}=1,\forall d,h \tag{15}$$

■ **交通可达性约束**:

若从景点i移动到j，其最早可到达时间槽(d',h')须满足路程耗时τ_{ij}，则有表达式：

$$w_{i,d,h}+w_{j,d',h'}\leqslant 1+\delta_{ij,d,h,d',h'},\ \ \delta_{ij,d,h,d',h'}=1\ if\ t_{d',h'}<t_{d,h}+\tau_{ij} \tag{16}$$

■ **预算与花费约束**:

若考虑交通与门票成本，设花费C_i（含到达成本）并给出游客预算$C_{\max}$，则需加入线性费用限制，则有不等式（17）：

$$\sum_{d=1}^{D}\sum_{h=1}^{H}C_iw_{i,d,h}\leqslant C_{\max} \tag{17}$$

■ **景点开放时间约束**:

景点仅在固定时段接待游客，也即：

$$w_{i,d,h}=0,\forall i,\forall d,\forall h\notin H_i^{open} \tag{18}$$

■ **最短游览时长约束**:

为了保证观赏体验，进入景点后至少停留m_i个时间槽，则可列出不等式（19）：

$$\sum_{h'=h+m_i-1}^{h} w_{i,d,h'}\geq m_i(w_{i,d,h}-w_{i,d,h-1}),\forall i,d,h \tag{19}$$

■ **每日起始与结束时间**:

假设游客每天最早 08:00 出发、最晚 19:00 返程，对应时间槽区间 $[h_{start},h_{end}]$。

$$w_{i,d,h}=0,\forall i,d,h<h_{start}或h>h_{end} \tag{20}$$

■ **景点不重复访问**:

清明假期天数有限，因此本文规定同一景点不重复到访，也就有：

$$\sum_{d=1}^{D}\sum_{h=1}^{H} w_{i,d,h}\leq H,\forall i \tag{21}$$

■ **每日总步行/车程时长上限**:

长距离奔波会导致旅途疲劳，因此我们为总步行和总车程时长设置一个上确界，则有不等式（22）：

$$\sum_{h=1}^{H-1}\sum_{j\neq i}\tau_{ij}y_{i,j,d,h}\leq T_{\max},\forall d \tag{22}$$

$$y_{i,j,d,h}\geq w_{i,d,h}+w_{i,d,h+1}-1,y_{i,j,d,h}\in\{0,1\} \tag{23}$$

7.3 多约束整数规划模型的求解

综合 7.1.1、7.1.2、7.1.3 节分别确立的决策变量、目标函数和约束条件，我们有如下的多约束整数规划模型（公式 24）。

基于气象预测数据与花期状态，我们建立了多目标优化模型，接下来通过 Matlab 编程就可以求解总观赏效用值以及游客密度和交通成本。选择总观赏效用值高的方案并综合考虑游客密度和交通成本，即可得出最终的清明假期三日最优行程规划。

$$\max \sum_{d=1}^{D}\sum_{h=1}^{H}\sum_{i=1}^{I} P_{i,t_{d,h}} \cdot w_{i,d,h}$$

$$s.t.\begin{cases} \sum_{i} w_{i,d,h} = 1, \forall d,h \\ w_{i,d,h} + w_{j,d',h'} \leq 1 + \delta_{ij,d,h,d',h'}, \quad \delta_{ij,d,h,d',h'} = 1 \ if \ t_{d',h'} < t_{d,h} + \tau_{ij} \\ \sum_{d=1}^{D}\sum_{h=1}^{H} C_i w_{i,d,h} \leq C_{\max} \\ w_{i,d,h} = 0, \forall i, \forall d, \forall h \notin H_i^{open} \\ \sum_{h'=h+m_i-1}^{h} w_{i,d,h'} \geq m_i (w_{i,d,h} - w_{i,d,h-1}), \forall i,d,h \\ w_{i,d,h} = 0, \forall i,d,h < h_{start} 或 h > h_{end} \\ \sum_{d=1}^{D}\sum_{h=1}^{H} w_{i,d,h} \leq H, \forall i \\ \sum_{h=1}^{H-1}\sum_{j \neq i} \tau_{ij} y_{i,j,d,h} \leq T_{\max}, \forall d \\ y_{i,j,d,h} \geq w_{i,d,h} + w_{i,d,h+1} - 1, y_{i,j,d,h} \in \{0,1\} \end{cases} \tag{24}$$

降雨概率柱状图与观赏指数值折线图及游客密度和交通成本热力图如下图 7-1 所示。我们选择满足降雨概率低、观赏指数高、游客密度低且交通成本低的城市和日期。

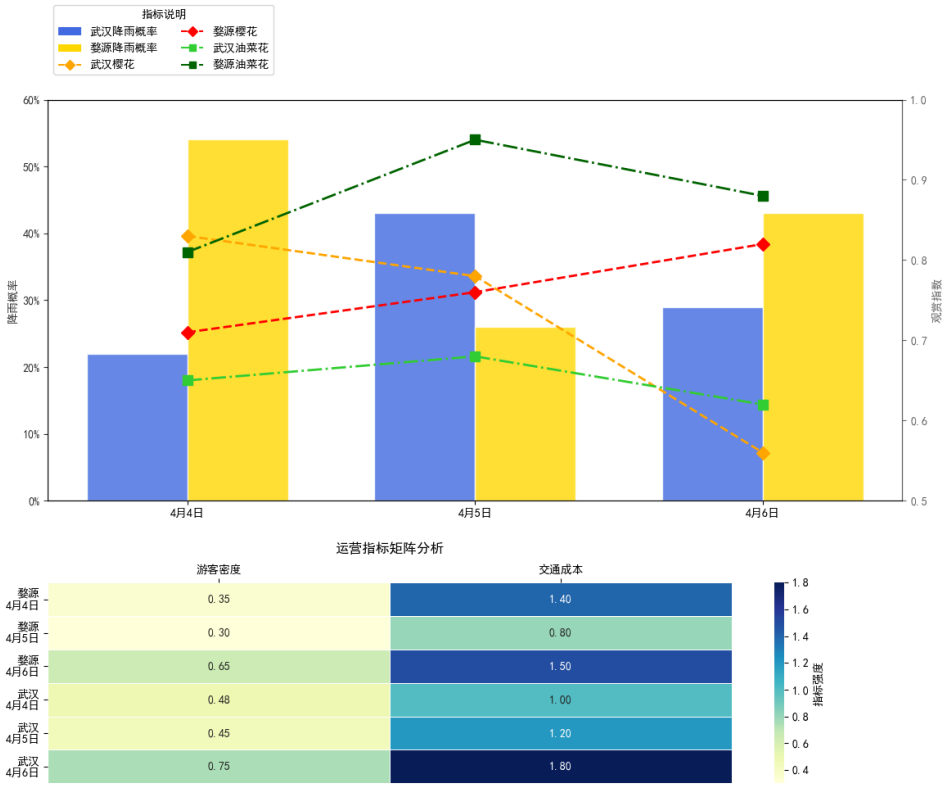


图 7-1 降雨概率柱状图、观赏指数值折线图、游客密度和交通成本热力图

最终得到的具体出行方案如下：

4 月 4 日 - 武汉

决策依据：选择武汉作为首日目的地的原因是樱花的观赏时效价值指数最高，达到了 0.85，同时武汉此刻的游客密度较小，为 0.48；交通成本较小，为 1.00。此外，武汉此时降雨概率仅为 22%，远小于婺源的 54%。综合考虑下，我们选择 4 月 4 日先去武汉赏樱花。

风险预案:

为应对可能的降雨，建议携带便携式雨具，并提前规划好室内的备用参观方案，以确保即使在不利天气条件下也能有丰富的游览体验。

4 月 5 日 - 婺源

决策依据: 第二天决定前往婺源的决定是基于天气降雨风险的持续降低，同时婺源油菜花花期处于盛花期，其综合观赏效用最高，达到了 0.97。正值油菜花的最佳观赏时期，且历史数据显示，婺源的游客密度较武汉低 20%，提供了更为宽松的游览环境。

风险预案: 为了更好地管理时间和资源，采用了分时段游览的策略，即上午专注于户外的自然景观，而下午则转向室内的文化展览，这样可以在享受美景的同时，也避免了因天气变化带来的不便。

4 月 6 日 - 婺源

决策依据: 第二天继续留在婺源的决定是基于婺源樱花观赏指数的上升，达到了 0.82,。同时，此举还减少了转场的必要，可以节省大约 2.5 小时的时间成本。除此之外，边际效用衰减率仅为 8%，意味着即使连续两日在同一地点游览，其吸引力仍然很高。

风险预案: 为了进一步提升时间的利用率，建议购买景区联票，这不仅能够节省购票的时间，还能提供更多的游览选择和灵活性。

八、问题四模型的建立与求解

8.1 经济效益评估模型的建立

8.1.1 设立动态游客需求函数

清明节假期游客量受花期延长天数T_f、宣传投入Y以及景区承载上限$K_{\max}$影响，由于花期延长和宣传投入对游客量的影响通常呈现边际效应递减或递增的非线性特征，因此采用非线性需求函数：

$$G(t)=\min\left(K_{\max},\ G_0\cdot \mathrm{e}^{\alpha T_f+\beta Y}\cdot\frac{1}{1+e^{-\gamma(W(t)-0.5)}}\right) \tag{25}$$

其中，$W(t)$为天气效用（$W(t)=1-$降雨概率），G_0为基准游客量（未延长花期的日均游客量），α,β是通过历史数据回归确定的，分别表示花期延长和宣传投入对游客量的边际效应。

8.1.2 建立人均消费模型

游客消费分为门票、交通、食宿&购物三类，通过历史消费数据可知，这三类与景区吸引力成正相关，因此总消费为：

$$C(t)=a_t+b_t+c_t \tag{26}$$

其中，a_t为门票支出，b_t为交通支出，c_t为食宿及购物支出。

8.1.3 计算直接旅行收入

在花期$T=T_f$天内，直接收入为游客量与人均消费的积分，计算公式如下：

$$R_{income}=\int_0^T G(t)\cdot C(t)dt \tag{27}$$

8.1.4 设定投资成本函数

总投资成本包括固定成本C_0和运维成本（按直接收入比例计算），计算公式如下：

$$C_{total}=C_0+\gamma R_{income} \tag{28}$$

其中，γ为运维成本率。

8.1.5 计算净效益收益与投资回报率（ROI）

净效益为直接收入减去总成本，投资汇报率衡量经济可行性：

$$\Pi=R_{income}-C_{total},\ \ ROI=\frac{\Pi}{C_{total}} \tag{29}$$

阈值要求：若$ROI\geq$基准值，则表示方案可行。

8.1.6 计算区域乘数效应与就业拉动的综合乘数

赏花经济通过产业链带动区域 GDP 和就业增长，基于区域经济投入产出表，定义产业链关联矩阵ρ_{ij}，计算综合乘数：

$$\Delta GDP=\sum_{i=1}^{n}\sum_{j=1}^{n}\rho_{ij}\cdot R_{income},\ \ \Delta E=\lambda R_{income} \tag{30}$$

8.1.7 对比经济增益

对比投资前后的经济增益：

$$\Delta R = R_{income} - R_{income}^{(0)} \tag{31}$$

其中，$R_{income}^{(0)}$表示未延长花期时的直接收入。

8.1.8 模型综合

综合 8.1-8.8 的计算公式，得到完整的经济效益评估模型如下：

$$\begin{cases} G(t) = \min\left(K_{\max},\ G_0 \cdot e^{\alpha T_f + \beta Y} \cdot \dfrac{1}{1 + e^{-\gamma(W(t) - 0.5)}}\right) \\ R_{income} = \sum_{t=1}^{L_f} G(t) \cdot (a_t + b_t + c_t) \\ C_{total} = C_0 + \gamma R_{income} \\ \Pi = R_{income} - C_{total}, ROI = \dfrac{\Pi}{C_{total}} \\ \Delta GDP = \mu R_{income}, \Delta E = \lambda R_{income} \\ \Delta R = R_{income} - R_{income}^{(0)} \end{cases} \tag{32}$$

公式（36）中的符号说明见下表 8-1。

表 8-1 问题四公式（36）符号说明

符号	说明	单位	符号	说明	单位
T_f	花期长度（延长后）	天	$C(t)$	人均消费	元/人次
Y	宣传投入金额	万元	R_{income}	直接旅游收入	万元
$K_{\max}$	景区单日最大承载游客量	人次/天	C_{total}	总投资成本	万元
G_0	基础日均游客量（未延长花期时	人次/天	ρ	产业间依存关系	
α, β	需求弹性系数（花期长度、宣传投入）		λ	单位收入就业拉动系数	岗位/万元

8.2 影响经济效益因素的相关性分析

通过查阅武汉旅游局官网的数据，我们得到了往年未加投资前，游客量、人均消费、旅游收入、花卉收入和产业链收入的具体数值，如下表 8-2。利用 Python 编程即可绘制出它们的散点图和随年份的变化趋势，如下图 8-1 所示。可以看出，随着年份增加，游客量、人均消费、旅游收入、花卉收入和产业链收入均呈现明显的上升趋势。其中，游客量从 378 万增长至 700 万，年均增长率为 7.2%；人均消费从 280 元提升至 600 元，年均增长率为 9.1%；旅游收入从 10.6 亿元增长至 21 亿元，年均增长率为 8.5%；花卉收入从 1.2 亿元增长至 7 亿元，年均增长率为 22.5%；产业链收入从 30 亿元增长至 65

亿元，年均增长率为 9.8%。

表 8-2 游客量、人均消费、旅游收入、花卉收入、产业链收入的往年数据

	游客量（万）	游客承载力（单日）	人均消费（元）	旅游收入（亿元）	樱花收入（亿元）	产业链收入（亿元）
2016	378	100	280	10.6	1.2	30
2017	408	110	300	11.5	2	35
2018	422.18	120	314.5	13.28	2.5	40
2019	580	125	500	15	3	45
2020	280	130	400	6	0.5	15
2021	350	140	450	9	1.8	27
2022	400	150	480	12	3	36
2023	550	160	550	14	4.2	45
2024	680	170	580	18	5.5	54
2025	700	180	600	21	7	65

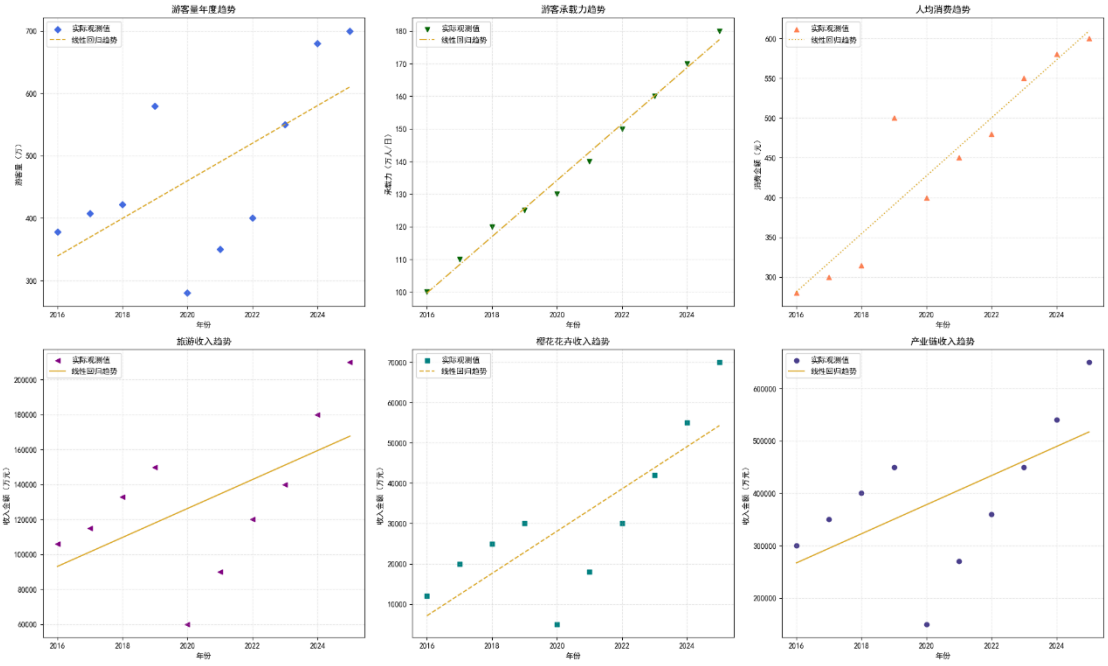


图 8-1 游客量、人均消费、旅游收入、花卉收入、产业链收入逐年变化规律

接着，我们对游客量、人均消费、旅游收入、花卉收入和产业链收入之间进行相关性分析，并绘制出如下图 8-2 所示的相关性热力图。

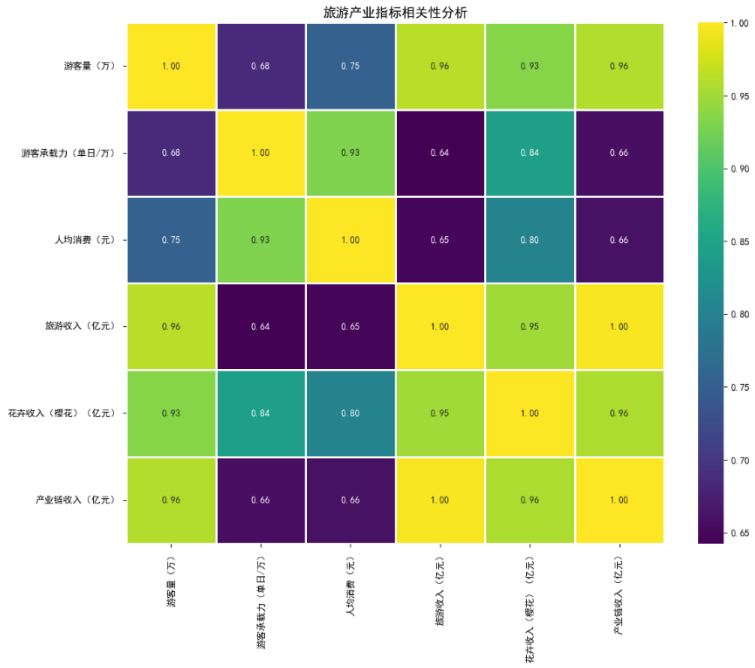


图 8-2 游客量、人均消费、旅游收入、花卉收入和产业链收入的相关性热力图

由热力图可知游客量与旅游收入、花卉收入（樱花）和产业链收入之间存在高度正相关关系，相关系数分别为 0.96、0.93 和 0.96；游客承载力与人均消费之间也存在较高的正相关关系，相关系数为 0.93；人均消费与旅游收入、花卉收入（樱花）和产业链收入之间也表现出较强的正相关关系，相关系数分别为 0.65、0.80 和 0.66；旅游收入与花卉收入（樱花）、产业链收入之间的高度正相关关系，相关系数均为 1.00；花卉收入（樱花）与产业链收入之间同样存在高度正相关关系，相关系数为 0.96。

总体来看，游客量和旅游收入是影响整个旅游产业链的关键因素，而游客承载力、人均消费和花卉收入也对产业链的收入产生重要影响。

因此我们可以得出结论：要把主要投资资金放在能够提升游客量和旅游收入的项目上；适当增加一些提升游客承载力、人均消费水平和花卉收入的措施能够实现经济效益最大化。

8.3 经济效益评估模型的求解

综合以上分析，利用 Matlab 编程求解模型（公式 36），得到如下 2000 万元投资资金的效益最大化分配比例（图 8-3）和产生的预期收益（表 8-3）：

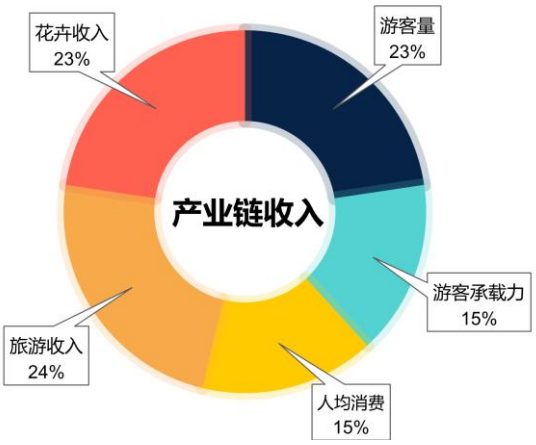


图 8-3 最大化经济效益投资比例

表 8-3 2000 万元投资资金的分配比例和预期收益

投资方向	投资金额（万元）	预期收益（万元）
提升游客承载力	800	1800
花卉特色项目开发	600	1500
精准营销推广	400	1100
产业链协同合作	200	500

得到的具体措施和产生的经济效益如下：

1、提升游客承载力（投资 800 万元）：

措施：扩建停车场容量至每日 5 万辆，新建观景平台和休息区。

效益：单日承载力从 180 万提升至 200 万，预计年游客量增加 50 万人次，带动旅游收入增长 1800 万元

2、花卉特色项目开发（投资 600 万元）：

措施：打造樱花夜间灯光秀（投资 300 万元），门票定价 50 元/人，预计吸引 30 万人次；开发花卉精油、花茶等衍生品（投资 300 万元），目标销售额 4000 万元。

效益：新增花卉收入 800 万元，产业链收入提升 1500 万元。

3、精准营销推广（投资 400 万元）：

措施：在社交媒体投放短视频广告，联合 KOL 推广“樱花季”活动。

效益：游客量增长 10%（20 万人次），旅游收入增加 1100 万元。

4、产业链协同合作（投资 200 万元）：

措施：与本地餐饮企业推出“樱花主题套餐”，与文创企业开发樱花纪念品。

效益：二次消费人均提升 50 元，带动产业链收入 500 万元。

通过以上比例科学分配 2000 万元投资至承载力提升、花卉项目开发、精准营销和产业链协同，预计可带动 **4900 万元** 的综合收益，投资回报率高达 **247%**。在这些措施中我们重点推荐优先实施 **花卉夜间灯光秀** 和 **社交媒体推广**，以快速提升游客量和消费水平。

九、模型的评价及优化

9.1 模型的优点（建模方法创新、求解特色等）

1.多模型融合，预测精度高

问题一采用 ARIMA 时间序列模型预测“雨纷纷”现象，通过 ADF 检验和 LB 检验确保数据平稳性和有效性，最终预测结果 RMSE≤0.1979，MAE≤0.1466，精度较高。

问题二结合有效积温模型与多元线性回归模型修正花期预测误差，使 RMSE 降至 3.96，精度提升至 95.36%，显著提高了预测准确性。

2.实用性强的行程优化模型

问题三构建的多约束整数规划模型综合考虑天气、花期、游客密度和交通成本等因素，通过 Matlab 求解得到最优赏花行程，实用性强，能为游客提供科学出行建议。

3.经济效益量化分析

问题四通过动态游客需求函数和产业链关联矩阵，量化分析延长花期和宣传投入的经济效益，提出投资分配方案（如夜间灯光秀、社交媒体推广），预期投资回报率达 247%，为政府决策提供数据支持。

4.数据驱动，逻辑清晰

模型均基于历史数据建立，通过相关性分析（如热力图）验证关键因素，逻辑严谨，结论可靠。

9.2 模型的缺点

1.数据依赖性强，泛化能力有限

模型假设历史数据能反映未来趋势，但气候变化或突发事件（如疫情）可能导致预测偏差。花期预测仅针对油菜花和樱花，未涵盖其他春季花卉（如杏花、牡丹），适用范围有限。

2.主观参数设定影响结果

整数规划模型中景点吸引力权重、降雨惩罚函数灵敏度系数等参数依赖主观设定，可能影响最终行程规划的客观性。

3.经济模型简化过度

产业链乘数效应假设线性关系，未考虑区域经济结构的动态变化，可能高估实际收益。

9.3 模型的推广

1.文旅产业应用

可推广至其他季节性旅游场景（如红叶季、冰雪节），帮助景区优化资源配置。

2.农业领域延伸

花期预测模型可用于指导农作物种植和采摘计划，提升农业生产效率。

3.智慧城市管理

结合气象大数据，为城市公共活动（如马拉松、庆典）提供天气风险预警。

9.4 模型的改进

1.增强模型的鲁棒性

引入机器学习方法（如 LSTM 神经网络）处理非线性气象数据，提升长期预测的稳定性。增加更多花卉品种的物候学参数，扩大模型适用范围。

2.参数优化与敏感性分析

通过层次分析法（AHP）或熵权法客观确定景点权重，减少主观性。对关键参数（如宣传投入弹性系数）进行敏感性分析，明确其影响范围。

3.完善经济评估模型

采用投入产出分析法（IOA）替代简单乘数模型，更精准量化产业链带动效应。增加风险因子（如极端天气、政策变动）的蒙特卡洛模拟，评估收益波动性。

参考文献

[1] 李春晖,张晓芳,蔡哲,等.基于有效积温法改进婺源油菜花期预报模型[J].中国农业气象,2024,45(03):281-292.

[2] 竺可桢,宛敏渭.物候学[M].长沙:湖南教育出版社,1999.Zhu K Z,Wan M W.Phenology[M].Changsha:Hunan Education Publishing House,1999.(in Chinese)

[3] 谭静,陈正洪,肖玫. 武汉大学樱花花期长度特征及预报方法 [J]. 生态学报, 2021, 41 (01): 38-47.

[4] 郑明贵,李丽,于明. 中国 2025—2035 年稀土需求预测——基于灰色关联分析和 ARIMA-GM-BP 神经网络的组合模型 [J]. 稀土, 2025, 46 (02): 145-158.

[5] 罗木生,沈培志,马佳,等. 岸基航空兵多约束预先配置整数规划建模 [J]. 电光与控制, 2015, 22 (10): 35-38+72.

[6] 张敏宁. 基于灰色关联度分析的旅游经济效益影响因素研究──以广东省为例 [J]. 肇庆学院学报, 2023, 44 (06): 92-99.

附录 1

1、介绍：该代码是 MATLAB 编写，用来 ADF 单位根检验和白噪声检验

```
clear; clc;
%% 数据输入与初始化
% 输入近 20 年 4 月 4 日至 6 日三天降水量数据（2006-2025 年）
apr4Precip = [0.058889; 0; 0.13; 0; 0; 0; 0; 0.27; 0; 0.41; 0; 0.01; 0.24; 0; 0; 0; 0; 0.058889; 0; 0]; % 4 月 4 日数据
apr5Precip = [0.02; 0; 0; 0; 0; 0.03; 0; 0; 0; 0.08; 0.07; 0; 0.11; 0; 0; 0; 0; 0.09; 0; 0]; % 4 月 5 日数据
apr6Precip = [0.010526; 0; 0; 0; 0; 0; 0; 0; 0; 0.09; 0.06; 0; 0.05; 0; 0; 0; 0; 0; 0; 0]; % 4 月 6 日数据
combined_precip = [apr4Precip; apr5Precip; apr6Precip]; % 合并时间序列

%% ADF 单位根检验与自动差分处理
% 初始化检验参数
max_differencing = 5; % 最大差分阶数（防止过度差分）
differencing_order = 0; % 当前累计差分次数
series_stationary = false; % 平稳性状态标志
current_series = combined_precip; % 当前待检验序列
adf_model_type = 'TS'; % ADF 检验模型类型（初始含趋势项和常数项）
significance_level = 0.05; % 显著性水平（常用 5% 检验标准）
% 自动差分与平稳性检验
while ~series_stationary && differencing_order < max_differencing
series_length = length (current_series);
if series_length < 2
error (' 数据长度不足，无法进行差分检验 ');
end
% 计算 ADF 检验最大滞后阶数（Schwert 准则）
max_lag_adf = floor (12 * (series_length / 100)^(1/4));
max_lag_adf = max (max_lag_adf, 0); % 确保非负滞后
% 基于 AIC 准则选择最优滞后阶数
aic_scores = inf (max_lag_adf + 1, 1); % 存储各滞后阶数的 AIC 值
for lag = 0:max_lag_adf
try
% 执行 ADF 检验并获取回归结果
[~, ~, ~, ~, regression_res] = adftest (current_series, 'Model', adf_model_type, 'Lags', lag);
aic_scores (lag + 1) = regression_res.AIC; % AIC 值越小模型拟合越好
catch
aic_scores (lag + 1) = inf; % 处理异常情况
end
end
[~, optimal_lag_index] = min (aic_scores); % 寻找最小 AIC 对应的滞后阶数
optimal_lag_adf = optimal_lag_index - 1; % 转换为 0-based 索引
% 执行 ADF 单位根检验
[stationary_flag, p_value, adf_statistic, critical_values] = ...
adftest (current_series, 'Model', adf_model_type, 'Lags', optimal_lag_adf, 'Alpha', significance_level);
% 输出检验结果
fprintf ('\n------ 差分阶数: % d ------\n', differencing_order);
fprintf ('ADF 统计量: %.4f\n', adf_statistic);
if length (critical_values) >= 3 % 显示多水平临界值
fprintf ('1%% 临界值: %.4f\n5%% 临界值: %.4f\n10%% 临界值: %.4f\n', ...
critical_values (1), critical_values (2), critical_values (3));
else % 仅显示默认 5% 临界值
fprintf ('5%% 显著性临界值: %.4f\n', critical_values (1));
```

```
end
fprintf ('p 值: %.4f\n 检验结果 (h=1 表示平稳): % d\n', p_value, stationary_flag);
% 判断是否达到平稳性
if stationary_flag
series_stationary = true;
fprintf (' 序列在 % d 阶差分后满足平稳性要求。\n', differencing_order);
else % 执行差分并更新模型类型（去除趋势项）
current_series = diff (current_series); % 一阶差分
differencing_order = differencing_order + 1;
adf_model_type = 'ARD'; % 差分后模型假设无趋势项（随机游走模型）
fprintf (' 执行第 % d 阶差分后序列长度: % d\n', differencing_order, length (current_series));
end
end
% 输出最终平稳性结果
if series_stationary
fprintf ('\n------ 平稳性检验完成 ------\n');
fprintf (' 最终差分阶数: % d\n', differencing_order);
else
warning (' 达到最大差分阶数仍未平稳，可能需要检查数据特性或调整参数 ');
end

%% 白噪声检验（针对平稳序列）
% 设置检验参数
lb_test_alpha = 0.05; % 白噪声检验显著性水平
stationary_series_length = length (current_series);
% 选择滞后阶数（采用平方根法则，不超过 12 阶）
lb_test_lag = min (floor (sqrt (stationary_series_length)), 12);
% 执行 Ljung-Box（LB）白噪声检验
[non_white_noise_flag, lb_p_value, q_statistic, lb_critical] = ...
lbqtest (current_series, 'Lags', lb_test_lag, 'Alpha', lb_test_alpha);
% 输出检验结果
fprintf ('\n------ 白噪声检验结果 ------\n');
fprintf (' 检验滞后阶数: % d\n', lb_test_lag);
fprintf ('Q 统计量: %.4f\n% d%% 临界值: %.4f\n', q_statistic, (1 - lb_test_alpha) * 100, lb_critical);
fprintf ('p 值: %.4f\n 检验结果 (h=1 表示非白噪声): % d\n', lb_p_value, non_white_noise_flag);
if non_white_noise_flag
fprintf (' 结论：序列存在自相关性，非白噪声（即序列中的观测值存在相关性或方差不恒定）。
\n');
else
fprintf (' 结论：序列无显著自相关性，属于白噪声（即序列中的观测值是独立的，且具有恒定
的方差）。\n');
end
% ---------- 代码说明 ----------
% 1. 采用 AIC 准则自动选择 ADF 检验的最优滞后阶数，避免主观设定
% 2. 差分过程中自动调整模型类型，从含趋势项逐步转为无趋势项
% 3. 白噪声检验滞后阶数采用数据驱动方法（平方根法则），兼顾检验效力与自由度
% 4. 关键变量命名遵循 "用途_方法" 规范，增强代码可读性
```

附录 2

2、介绍：该代码是 MATLAB 编写的，作用是 ARIMA 模型的建立及预测，PACF 图和 ACF 图的绘制，模型验证，对比图的绘制

```
%% 基于 ARIMA 模型的降水量预测分析（2006-2025 年）
%% 数据输入与预处理
% 原始数据输入（近 20 年 4 月 4 至 6 日降水量，单位：mm）
apr4Precip = [0.058889; 0; 0.13; 0; 0; 0; 0; 0.27; 0; 0.41; 0; 0.01; 0.24; 0; 0; 0; 0; 0.058889; 0; 0];  % 4 月 4 日数据
apr5Precip = [0.02; 0; 0; 0; 0; 0.03; 0; 0; 0; 0.08; 0.07; 0; 0.11; 0; 0; 0; 0; 0.09; 0; 0];  % 4 月 5 日数据
apr6Precip = [0.010526; 0; 0; 0; 0; 0; 0; 0; 0; 0.09; 0.06; 0; 0.05; 0; 0; 0; 0; 0; 0; 0];  % 4 月 6 日数据
% 时间序列数据分割（前 10 年训练，后 10 年测试）
trainYears = 10; % 训练集时间跨度（2006-2015 年，共 10 年）
testYears = 20 - trainYears;  % 测试集时间跨度（2016-2025 年，共 10 年）
% 按时间顺序分割各日数据
apr4Train = apr4Precip(1:trainYears);        % 4 月 4 日训练数据（前 10 年）
apr4Test = apr4Precip(trainYears+1:end);   % 4 月 4 日测试数据（后 10 年）
apr5Train = apr5Precip(1:trainYears);        % 4 月 5 日训练数据（前 10 年）
apr5Test = apr5Precip(trainYears+1:end);   % 4 月 5 日测试数据（后 10 年）
apr6Train = apr6Precip(1:trainYears);        % 4 月 6 日训练数据（前 10 年）
apr6Test = apr6Precip(trainYears+1:end);   % 4 月 6 日测试数据（后 10 年）
%% 历史降水特征统计
% "雨纷纷"统计（定义降水量需满足 0.1-9.9mm）
% 定义"雨纷纷"判断函数
isValidRain = @(x) (x >= 0.1) & (x <= 9.9);
% 统计各日历史"雨纷纷"年数（20 年中满足条件的年份数）
validRainYears = [
    sum(isValidRain(apr4Precip));   % 4 月 4 日"雨纷纷"年数
    sum(isValidRain(apr5Precip));   % 4 月 5 日"雨纷纷"年数
    sum(isValidRain(apr6Precip))    % 4 月 6 日"雨纷纷"年数
];
% 计算 4 月 4 至 6 日单日"雨纷纷"概率及三日联合概率
dailyRainProb = validRainYears / 20 * 100;      % 单日"雨纷纷"概率（20 年统计）
probNoRainCombined = prod(1 - dailyRainProb/100);  % 三天均无"雨纷纷"的概率
rainyCombinedProb = (1 - probNoRainCombined) * 100;  % 三天内出现"雨纷纷"的概率
%% 并行计算环境配置
% 启动并行计算加速模型训练
if isempty(gcp('nocreate'))
    parpool('Processes', 3);  % 启动 3 个进程的并行池（对应三天数据）
end
parallelPool = gcp();  % 获取当前并行池对象
parallelPool.addAttachedFiles(pwd);  % 同步当前路径到所有工作进程
%% 分日 ARIMA 模型训练与验证
% 数据容器初始化（存储训练/测试序列）
trainingData = repmat(struct('timeSeries', []), 3, 1);  % 训练数据结构体数组
testingData = repmat(struct('timeSeries', []), 3, 1);    % 测试数据结构体数组
% 填充各日训练/测试数据
trainingData(1).timeSeries = apr4Train;
trainingData(2).timeSeries = apr5Train;
trainingData(3).timeSeries = apr6Train;
```

```
testingData(1).timeSeries = apr4Test;
testingData(2).timeSeries = apr5Test;
testingData(3).timeSeries = apr6Test;
% 并行训练 ARIMA 模型（动态确定模型阶数）
modelParams = cell(3, 1);            % 存储各日模型参数（p, q）
testPredictions = cell(3, 1);     % 存储各日测试集预测结果
parfor dayIdx = 1:3
    % 初始化预测向量（长度等于测试集年份数）
    predVector = zeros(testYears, 1);
    % 提取当前日训练/测试序列
    trainSeries = trainingData(dayIdx).timeSeries;
    testSeries = testingData(dayIdx).timeSeries;
    trainLen = length(trainSeries);
    % 计算一阶差分序列（用于平稳化处理）
    diffSeries = diff(trainSeries);   % 差分后序列长度 = 原长度 - 1
    diffLen = length(diffSeries);
    % 动态确定 PACF/ACF 最大滞后数（避免超过数据长度限制）
    maxLag = min(10, diffLen - 1);   % 最大滞后数不超过 10 或差分后序列长度-1
    maxLag = max(maxLag, 0);   % 处理极小样本情况
    % 基于 PACF 确定 AR 阶数 p
    [pacfVals, ~] = parcorr(diffSeries, 'NumLags', maxLag);   % 计算偏自相关函数
    significanceThresh = 2 / sqrt(diffLen);   % 95%置信度临界值
    if isempty(pacfVals) || all(abs(pacfVals) <= significanceThresh)
        arOrder = 0;   % 无显著偏自相关，p=0
    else
        % 找到最后一个显著滞后阶数，限制 p≤5 防止过拟合
        lastSignificantLag = find(abs(pacfVals) > significanceThresh, 1, 'last');
        arOrder = min(lastSignificantLag, 5);
    end
    % 基于 ACF 确定 MA 阶数 q
    [acfValsFull, ~] = autocorr(diffSeries, 'NumLags', maxLag);   % 计算自相关函数
    acfVals = acfValsFull(2:end);   % 移除滞后 0 项
    if isempty(acfVals) || all(abs(acfVals) <= significanceThresh)
        maOrder = 0;   % 无显著自相关，q=0
    else
        % 找到最后一个显著滞后阶数，限制 q≤5 防止过拟合
        lastSignificantLag = find(abs(acfVals) > significanceThresh, 1, 'last');
        maOrder = min(lastSignificantLag, 5);
    end
    % ARIMA 模型训练与预测
    try
        % 定义 ARIMA 模型（d=1 表示一阶差分）
        arimaModel = arima('ARLags', 1:arOrder, 'D', 1, 'MALags', 1:maOrder);
        fittedModel = estimate(arimaModel, trainSeries, 'Display', 'off');   % 模型拟合
        [predVector, ~] = forecast(fittedModel, testYears, 'Y0', trainSeries);   % 多步预测
        predVector = max(predVector, 0);   % 确保降水量非负
    catch ME
        warning(sprintf('第%d 日建模失败，使用历史均值预测: %s', dayIdx, ME.message));
        predVector = repmat(mean(trainSeries), testYears, 1);   % 异常时使用均值预测
        arOrder = 0;
        maOrder = 0;
    end
    testPredictions{dayIdx} = predVector;   % 存储预测结果
```

```
    modelParams{dayIdx} = struct('p', arOrder, 'q', maOrder);    % 存储模型参数
end
%% 模型预测效果评估
% 计算评估指标（RMSE/MAE/R²）
evaluationMetrics = cell(3, 1);    % 存储各日评估结果
testTrueValues = cell(3, 1);        % 存储测试集真实值
testPredValues = cell(3, 1);        % 存储测试集预测值
for dayIdx = 1:3
    trueVals = testingData(dayIdx).timeSeries;    % 真实降水量序列
    predVals = testPredictions{dayIdx};              % 预测降水量序列
    testTrueValues{dayIdx} = trueVals;
    testPredValues{dayIdx} = predVals;
    % 均方根误差（RMSE）
    rmse = sqrt(mean((predVals - trueVals).^2));
    % 平均绝对误差（MAE）
    mae = mean(abs(predVals - trueVals));
    % 决定系数（R²）
    totalSumSq = sum((trueVals - mean(trueVals)).^2);
    if totalSumSq == 0
        rSquared = NaN;    % 数据全为 0 时无法计算
    else
        rSquared = 1 - (sum((predVals - trueVals).^2) / totalSumSq);
    end
    evaluationMetrics{dayIdx} = struct( ...
        'RMSE', rmse, ...
        'MAE', mae, ...
        'R2', rSquared ...
    );
end
%% 预测结果可视化
% 测试集预测值与真实值对比图
figure('Position', [100 100 1000 800], 'Color', 'white');
dateTitles = {'4 月 4 日', '4 月 5 日', '4 月 6 日'};    % 各日图表标题
for dayIdx = 1:3
    subplot(3, 1, dayIdx);    % 创建 3 行 1 列子图
    testYearRange = 2016:2025;    % 测试集年份范围
    % 绘制真实值（蓝色实心圆点连线）
    plot(testYearRange, testTrueValues{dayIdx}, 'bo-', ...
        'LineWidth', 1.5, 'MarkerFaceColor', 'b', 'DisplayName', '实际值');
    hold on;
    % 绘制预测值（红色星号连线）
    plot(testYearRange, testPredValues{dayIdx}, 'r*-', ...
        'LineWidth', 1.5, 'MarkerFaceColor', 'r', 'DisplayName', '预测值');
    title(sprintf('%s 降水量对比（2016-2025）', dateTitles{dayIdx}), 'FontSize', 12);
    xlabel('年份');
    ylabel('降水量 (mm)');
    % 动态调整 y 轴范围（显示真实值和预测值的 110%）
    maxTrue = max(testTrueValues{dayIdx});
    maxPred = max(testPredValues{dayIdx});
    ylim([0, max(maxTrue, maxPred) * 1.1]);
    grid on;    % 显示网格线
    legend('show', 'Location', 'northeast');    % 显示图例
end
```

```
%% 模型验证报告输出
% 打印模型评估结果
disp('==================== 模型验证报告 ====================');
disp('数据分割：前 10 年训练（2006-2015），后 10 年测试（2016-2025）');
disp('------------------------------------------------------------');
disp('指标说明：');
disp('  RMSE（均方根误差）：反映预测值与实际值的平均偏差（单位：mm，值越小预测越准确）');
disp('  MAE（平均绝对误差）：反映预测值与实际值的绝对偏差平均值（单位：mm，值越小预测越准确）');
disp('  R² （决定系数）：模型解释数据方差的比例（1 为完美预测，0 为仅预测均值，负值表示效果差于均值）');
disp('------------------------------------------------------------');
for dayIdx = 1:3
    fprintf('%s 预测结果：\n', dateTitles{dayIdx});
    fprintf('  RMSE: %.4f mm\n', evaluationMetrics{dayIdx}.RMSE);
    fprintf('  MAE: %.4f mm\n', evaluationMetrics{dayIdx}.MAE);

    if isnan(evaluationMetrics{dayIdx}.R2)
        fprintf('  R²: NaN（数据全为 0，无法评估模型拟合效果）\n');
    elseif evaluationMetrics{dayIdx}.R2 < 0
        fprintf('  R²: %.4f（模型预测效果差于直接使用历史均值）\n', evaluationMetrics{dayIdx}.R2);
    else
        fprintf('  R²: %.4f（模型有效拟合数据趋势）\n', evaluationMetrics{dayIdx}.R2);
    end

    disp('--------------------------------------------------');
end
%% 2026 年降水量预测 ------------------------
% 基于全量数据预测 2026 年各日降水量
fullDataset = repmat(struct('fullSeries', []), 3, 1);  % 全量数据容器
fullDataset(1).fullSeries = apr4Precip;
fullDataset(2).fullSeries = apr5Precip;
fullDataset(3).fullSeries = apr6Precip;
pred2026 = zeros(3, 1);  % 存储 2026 年三天预测结果
for dayIdx = 1:3
    fullSeries = fullDataset(dayIdx).fullSeries;  % 20 年全量数据
    arOrder = modelParams{dayIdx}.p;                % 训练得到的 AR 阶数
    maOrder = modelParams{dayIdx}.q;                % 训练得到的 MA 阶数
    try
        % 使用全量数据训练模型并预测下一年
        arimaModel = arima('ARLags', 1:arOrder, 'D', 1, 'MALags', 1:maOrder);
        fittedModel = estimate(arimaModel, fullSeries, 'Display', 'off');
        [singlePred, ~] = forecast(fittedModel, 1, 'Y0', fullSeries);  % 1 步预测
        pred2026(dayIdx) = max(singlePred, 0);  % 确保非负
    catch
        pred2026(dayIdx) = mean(fullSeries);  % 异常时使用历史均值预测
    end
end
% 输出 2026 年预测结果
disp('==================== 2026 年 4 月预测结果 ====================');
predictionDates = datetime(2026, 4, 4:6)';  % 预测日期
```

```
dailyRainProbability = dailyRainProb(:);          % 转换为列向量
% 创建结果表格
resultTab = table( ...
    predictionDates, ...
    pred2026, ...
    dailyRainProbability, ...
    'VariableNames', {'日期', '预测降水量(mm)', '历史雨纷纷概率(%)'} ...
);
disp(resultTab);
disp(' ');
disp(sprintf('2026 年 4 月 4 日至 6 日三天内出现“雨纷纷”的概率：%.2f%%', rainyCombinedProb));
%% ACF/PACF 特征分析
% 绘制合并序列的自相关与偏自相关图
combinedSeries = [apr4Precip; apr5Precip; apr6Precip];  % 合并三天降水序列
totalLength = length(combinedSeries);
maxCorrLag = floor(totalLength/3);  % 最大滞后数设为序列长度的三分之一
confidenceThresh = 2 / sqrt(totalLength);  % 95%置信区间临界值
% 计算自相关函数（ACF）和偏自相关函数（PACF）
[acfVals, acfLags] = autocorr(combinedSeries, 'NumLags', maxCorrLag);
acfVals = acfVals(2:end);  % 移除滞后 0 项
acfLags = acfLags(2:end);
[pacfVals, pacfLags] = parcorr(combinedSeries, 'NumLags', maxCorrLag);
% 确定全局模型参数（用于图表标题）
if isempty(pacfVals) || all(abs(pacfVals) <= confidenceThresh)
    globalArOrder = 0;
else
    globalArOrder = min(find(abs(pacfVals) > confidenceThresh, 1, 'last'), 5);
end
if isempty(acfVals) || all(abs(acfVals) <= confidenceThresh)
    globalMaOrder = 0;
else
    globalMaOrder = min(find(abs(acfVals) > confidenceThresh, 1, 'last'), 5);
end
% 绘制 ACF/PACF 图
figure('Position', [100 100 1200 600], 'Color', 'white');
% ACF 子图
subplot(2, 1, 1);
stem(acfLags, acfVals, 'filled', 'MarkerSize', 4, 'LineWidth', 1.2);
hold on;
% 绘制置信区间区域
fill([0, max(acfLags), max(acfLags), 0], [confidenceThresh, confidenceThresh, -confidenceThresh,
-confidenceThresh], ...
     [0.9 0.9 1], 'FaceAlpha', 0.3, 'EdgeColor', 'none');
% 绘制参考线
plot([0, max(acfLags)], [0, 0], 'k--', 'LineWidth', 1);
plot([0, max(acfLags)], [confidenceThresh, confidenceThresh], 'r--', 'LineWidth', 0.8);
plot([0, max(acfLags)], [-confidenceThresh, -confidenceThresh], 'r--', 'LineWidth', 0.8);
title(sprintf('合并序列 ACF 图（2006-2025） | MA 阶数 q=%d', globalMaOrder), 'FontSize', 12,
'FontWeight', 'bold');
xlabel('滞后项 (Lag)');
ylabel('ACF 值');
xlim([0, max(acfLags)]);
ylim([-1, 1]);
grid on;
```

```
% PACF 子图
subplot(2, 1, 2);
stem(pacfLags, pacfVals, 'filled', 'MarkerSize', 4, 'LineWidth', 1.2);
hold on;
fill([0, max(pacfLags), max(pacfLags), 0], [confidenceThresh, confidenceThresh, -confidenceThresh,
-confidenceThresh], ...
        [0.9 0.9 1], 'FaceAlpha', 0.3, 'EdgeColor', 'none');
plot([0, max(pacfLags)], [0, 0], 'k--', 'LineWidth', 1);
plot([0, max(pacfLags)], [confidenceThresh, confidenceThresh], 'r--', 'LineWidth', 0.8);
plot([0, max(pacfLags)], [-confidenceThresh, -confidenceThresh], 'r--', 'LineWidth', 0.8);
title(sprintf('合并序列 PACF 图（2006-2025） | AR 阶数 p=%d', globalArOrder), 'FontSize', 12,
'FontWeight', 'bold');
xlabel('滞后项 (Lag)');
ylabel('PACF 值');
xlim([0, max(pacfLags)]);
ylim([-1, 1]);
grid on;
disp('===== ARIMA 模型全局参数识别结果 =====');
disp(['AR 阶数 p = ', num2str(globalArOrder)]);
disp(['MA 阶数 q = ', num2str(globalMaOrder)]);
%% 资源清理
% 关闭并行计算池
delete(gcp('nocreate'));
```

附录 3：说明

其余问题代码过于冗长，详情请见支撑材料中的代码。以下是支撑材料包截图。

